

Prédiction des Retards de Vols

Classification Binaire par Machine Learning

Résumé du Projet

Ce rapport présente une étude complète de prédiction des retards de vols aériens à partir d'un dataset de plus de 3 millions d'enregistrements. Quatre modèles de Machine Learning sont comparés : Régression Logistique, Random Forest, XGBoost et LightGBM. Le meilleur modèle (XGBoost) atteint un ROC-AUC de **0.664** sur l'ensemble de test.

Domaine	Transport Aérien / Prédiction
Type de tâche	Classification Binaire Supervisée
Dataset	3 000 000 vols, 31 variables
Variable cible	Retard à l'arrivée ≥ 15 min
Environnement	Python 3.12, scikit-learn, XGBoost, LightGBM
Déploiement	Application Streamlit

Table des matières

1	Introduction et Contexte	2
1.1	Problématique	2
1.2	Objectifs	2
1.3	Enjeux Industriels	2
2	Description des Données	3
2.1	Structure du Dataset	3
2.2	Variables Principales	3
3	Nettoyage et Préparation des Données	4
3.1	Analyse des Valeurs Manquantes	4
3.2	Étapes de Nettoyage	4
3.3	Ingénierie des Variables (Feature Engineering)	4
3.4	Variables Utilisées pour la Modélisation	5
4	Analyse Exploratoire des Données (EDA)	6
4.1	Distribution de la Variable Cible	6
4.2	Analyse Temporelle	6
4.2.1	Saisonnalité Mensuelle	6
4.2.2	Effet du Jour de la Semaine	6
4.2.3	Impact de l'Heure de Départ	6
4.3	Analyse Géographique	6
4.4	Distribution du Retard en Minutes	7
5	Modèles de Machine Learning	8
5.1	Choix des Algorithmes	8
5.1.1	1. Régression Logistique (Baseline)	8
5.1.2	2. Random Forest	8
5.1.3	3. XGBoost (Extreme Gradient Boosting)	8
5.1.4	4. LightGBM (Light Gradient Boosting Machine)	8
5.2	Gestion du Déséquilibre de Classes	8
6	Évaluation des Performances	10
6.1	Métriques d'Évaluation	10
6.2	Tableau Comparatif des Résultats	10
6.3	Analyse des Résultats par Modèle	10
6.3.1	Régression Logistique	10
6.3.2	Random Forest	10
6.3.3	XGBoost — Meilleur Modèle	11
6.3.4	LightGBM	11
6.4	Interprétation des Matrices de Confusion	11
6.5	Importance des Variables	11

7	Limites et Améliorations Proposées	12
7.1	Limites Actuelles	12
7.2	Pistes d'Amélioration	12
7.2.1	Amélioration des Données	12
7.2.2	Amélioration des Modèles	12
7.2.3	Amélioration du Déploiement	12
8	Déploiement de l'Application Streamlit	13
8.1	Architecture de l'Application	13
8.2	Structure du Projet	13
8.3	Instructions de Déploiement	13
8.4	Fonctionnalités de l'Application	14
9	Conclusion	15
9.1	Synthèse	15
9.2	Perspectives	15
9.3	Valeur Métier	15

Introduction et Contexte

Problématique

Les retards de vols constituent l'un des défis majeurs du transport aérien mondial. Selon les données de l'IATA (International Air Transport Association), les retards coûtent annuellement plusieurs milliards d'euros aux compagnies aériennes, aux aéroports et aux passagers. En Europe, environ 20% des vols arrivent avec un retard supérieur à 15 minutes, ce qui représente un impact économique et opérationnel considérable.

Définition officielle du retard

Un vol est officiellement considéré comme **retardé** lorsque son retard à l'arrivée est supérieur ou égal à **15 minutes** par rapport à l'heure programmée, conformément aux normes FAA (Federal Aviation Administration) et aux directives IATA.

Objectifs

Ce projet vise à :

- Analyser un dataset massif de vols aériens (3 millions d'entrées)
- Développer des modèles prédictifs pour anticiper les retards
- Comparer les performances de plusieurs algorithmes de classification
- Déployer une application interactive de prédiction en temps réel
- Formuler des recommandations pratiques pour les opérateurs aériens

Enjeux Industriels

La prédiction précoce des retards permet :

1. D'optimiser l'affectation des équipages et des aéronefs
2. De notifier les passagers à l'avance pour réduire l'insatisfaction
3. De minimiser les effets cascade (retards propagés entre vols)
4. D'améliorer la gestion des portes d'embarquement dans les hubs
5. De réduire les coûts opérationnels liés aux compensations passagers

Description des Données

Structure du Dataset

Le dataset `data_vols_1.csv` contient **3 000 000 enregistrements** de vols commerciaux avec 31 variables couvrant les informations de départ, d'arrivée, les retards par catégorie et les caractéristiques opérationnelles.

TABLE 1 – Statistiques globales du dataset

Indicateur	Valeur	Unité
Total d'enregistrements	3 000 000	vols
Variables disponibles	31	colonnes
Vols retenus (après nettoyage)	490 011	vols
Vols retardés (≥ 15 min)	93 262	vols
Taux de retard global	19,03	%
Retard moyen à l'arrivée	4,92	minutes
Retard médian à l'arrivée	-5,0	minutes
Retard maximum observé	1 554	minutes
Aéroports de départ distincts	318	aéroports
Compagnies aériennes	12	compagnies
Types d'avions	4 106	aéronefs

Variables Principales

TABLE 2 – Description des variables clés

Variable	Type	Description
RETARD À L'ARRIVÉE	Float (cible)	Retard en minutes à l'arrivée
AÉROPORT DÉPART	Catégorielle	Code IATA de l'aéroport d'origine
AÉROPORT ARRIVÉE	Catégorielle	Code IATA de l'aéroport de destination
COMPAGNIE RIENNE	AÉ- Catégorielle	Code de la compagnie opérante
DÉPART PROGRAMMÉ	Entier	Heure de départ prévue (HHMM)
DISTANCE	Entier	Distance du vol en kilomètres
TEMPS PROGRAMMÉ	Float	Durée de vol programmée (minutes)
DATE	String	Date du vol (JJ/MM/AAAA)
NIVEAU DE SÉCURITÉ	Entier	Score de sécurité opérationnelle
RETARD MÉTÉO	Float	Part du retard due à la météo
RETARD COMPAGNIE	Float	Part du retard due à la compagnie
RETARD AVION	Float	Part du retard due à l'appareil
ANNULATION	Binaire	Indicateur d'annulation du vol
DÉTOURNEMENT	Binaire	Indicateur de détournement

Nettoyage et Préparation des Données

Analyse des Valeurs Manquantes

Le dataset présente des valeurs manquantes significatives dans certaines colonnes, notamment les causes de retard :

- **RAISON D'ANNULATION** : 98,26% de valeurs manquantes (normale pour les vols non annulés)
- **RETARD SYSTÈME / SÉCURITÉ / COMPAGNIE / AVION / MÉTÉO** : 81,48% manquants
- **COMPAGNIE AÉRIENNE** : 4,75% manquants
- **HEURE DE DÉPART / RETARD DE DÉPART** : 1,65% manquants

Décision de traitement

Les colonnes de causes de retard (RETARD SYSTÈME, RETARD MÉTÉO, etc.) ont été exclues des features d'entraînement car elles ne sont pas disponibles *a priori* avant le vol — les inclure constituerait une fuite de données (*data leakage*).

Étapes de Nettoyage

1. **Exclusion des vols annulés** : 1 742 vols supprimés (0,58%)
2. **Exclusion des vols détournés** : 297 vols supprimés (0,10%)
3. **Suppression des lignes sans retard** : 2 039 vols sans information d'arrivée
4. **Création de la variable cible** : $\text{RETARDÉ} = \mathbb{I}[\text{Retard} \geq 15]$
5. **Extraction de features temporelles** depuis la colonne DATE

Ingénierie des Variables (Feature Engineering)

À partir des données brutes, les features suivantes ont été construites :

Listing 1 – Création des features temporelles et encodage

```

1  # Variable cible binaire
2  df['RETARDE'] = (df["RETARD A L'ARRIVEE"] >= 15).astype(int)
3
4  # Features temporelles
5  df['DATE'] = pd.to_datetime(df['DATE'], dayfirst=True)
6  df['MOIS'] = df['DATE'].dt.month # Saisonnalité
7  df['JOUR_SEMAINE'] = df['DATE'].dt.dayofweek # Lundi=0,
   Dimanche=6
8  df['HEURE_DEP'] = df['DEPART PROGRAMME'] // 100 # Heure de
   d part
9
10 # Encodage des variables catégorielles
11 le_dep = LabelEncoder()
12 le_arr = LabelEncoder()
13 le_comp = LabelEncoder()

```

Variables Utilisées pour la Modélisation

TABLE 3 – Features retenues pour l’entraînement des modèles

Feature	Type	Justification
DÉPART PROGRAMMÉ	Numérique	Heure de vol intégrale
HEURE_DEP	Numérique	Heure extraite (0–23)
MOIS	Numérique	Saisonnalité annuelle
JOUR_SEMAINE	Numérique	Demande hebdomadaire
DISTANCE	Numérique	Longueur du trajet
TEMPS PROGRAMMÉ	Numérique	Durée de vol prévue
NIVEAU DE SÉCURITÉ	Numérique	Score opérationnel
AÉROPORT_DEP_ENC	Encodé	Aéroport d’origine
AÉROPORT_ARR_ENC	Encodé	Aéroport de destination
COMPAGNIE_ENC	Encodé	Opérateur aérien

Partitionnement : 80% entraînement (373 419 vols) / 20% test (93 355 vols), avec stratification sur la variable cible pour maintenir la proportion de classes.

Analyse Exploratoire des Données (EDA)

Distribution de la Variable Cible

Sur l'ensemble des 490 011 vols retenus :

- **396 749 vols** (80,97%) arrivent à l'heure ou avec moins de 15 minutes de retard
- **93 262 vols** (19,03%) sont considérés comme retardés (≥ 15 min)

Ce déséquilibre de classes (ratio 4 :1) est typique des problèmes de prédiction de retards et a orienté nos choix de modèles et d'hyperparamètres (utilisation de `class_weight='balanced'` et de `scale_pos_weight`).

Analyse Temporelle

Saisonnalité Mensuelle

L'analyse mensuelle révèle une saisonnalité marquée :

- Les mois d'été (**juin, juillet, août**) présentent des taux de retard plus élevés, liés à la densité du trafic et aux conditions météorologiques
- **Décembre et janvier** montrent également une hausse due aux conditions hivernales (verglas, neige, visibilité réduite)
- Les mois de **printemps** (mars-mai) sont généralement plus favorables

Effet du Jour de la Semaine

- **Vendredi et dimanche** : taux de retard les plus élevés, correspondant aux pics de trafic de fin de semaine
- **Mardi et mercredi** : jours les plus fluides, avec moins de congestion

Impact de l'Heure de Départ

La période de départ est l'un des facteurs les plus discriminants :

- **Vols matinaux** (5h–9h) : taux de retard minimal, l'avion commence sa rotation sans subir les retards accumulés de la journée
- **Vols du soir** (18h–22h) : taux de retard maximal, effet cascades des retards précédents
- Tendance croissante au fil de la journée (phénomène de *delay propagation*)

Analyse Géographique

Les 318 aéroports du dataset présentent des taux de retard très hétérogènes. Les aéroports avec les taux les plus élevés sont généralement :

- Des hubs importants avec une forte densité de trafic
- Des aéroports exposés à des conditions météorologiques défavorables
- Des plateformes de correspondance subissant l'effet cascade

Distribution du Retard en Minutes

La distribution du retard à l'arrivée présente une forme **asymétrique à droite** (skewness positif) :

- Médiane : -5 minutes (la majorité des vols arrivent légèrement en avance)
- Moyenne : $+4,92$ minutes (tirée vers le haut par les retards extrêmes)
- Maximum observé : $1\,554$ minutes (≈ 26 heures)
- Les valeurs extrêmes correspondent à des événements exceptionnels (pannes majeures, conditions climatiques sévères)

Modèles de Machine Learning

Choix des Algorithmes

Quatre algorithmes ont été sélectionnés pour couvrir un spectre de complexité :

Stratégie de sélection des modèles

Le choix s'est porté sur : (1) un modèle baseline linéaire, (2) un modèle d'ensemble basé sur les arbres, et (3) deux algorithmes de gradient boosting qui représentent l'état de l'art pour les données tabulaires.

1. Régression Logistique (Baseline)

Modèle linéaire servant de référence (*baseline*). Avantages : interprétabilité maximale, rapidité d'entraînement. Limites : ne capture pas les interactions non-linéaires entre variables.

Hyperparamètres : `max_iter=500, class_weight='balanced'`

2. Random Forest

Ensemble de 100 arbres de décision entraînés en parallèle. Robuste au bruit, peu sensible au réglage des hyperparamètres. Bonne interprétabilité via l'importance des features.

Hyperparamètres : `n_estimators=100, max_depth=12, class_weight='balanced'`

3. XGBoost (Extreme Gradient Boosting)

Algorithme de boosting par gradient utilisant des arbres CART. Régularisation L1/L2 intégrée, gestion native des valeurs manquantes. Optimal pour les données tabulaires structurées.

Hyperparamètres : `n_estimators=200, max_depth=6, learning_rate=0.1, scale_pos_weight`

4. LightGBM (Light Gradient Boosting Machine)

Variante de gradient boosting utilisant une stratégie de croissance feuille par feuille (*leaf-wise*) plutôt que niveau par niveau. Significativement plus rapide que XGBoost sur de grands datasets.

Hyperparamètres : `n_estimators=200, max_depth=8, learning_rate=0.1, class_weight='ba`

Gestion du Déséquilibre de Classes

Le ratio 80%/20% entre vols non-retardés et retardés nécessite des stratégies adaptées :

TABLE 4 – Stratégies de gestion du déséquilibre par modèle

Modèle	Stratégie
Régression Logistique	<code>class_weight='balanced'</code>
Random Forest	<code>class_weight='balanced'</code>
XGBoost	<code>scale_pos_weight = n_neg / n_pos $\approx$ 4.25</code>
LightGBM	<code>class_weight='balanced'</code>

Évaluation des Performances

Métriques d'Évaluation

Pour un problème de classification avec déséquilibre de classes, plusieurs métriques complémentaires sont nécessaires :

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN} \tag{1}$$

$$\text{Précision} = \frac{VP}{VP + FP} \tag{2}$$

$$\text{Rappel} = \frac{VP}{VP + FN} \tag{3}$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \tag{4}$$

$$\text{ROC-AUC} = \int_0^1 \text{TPR}(\text{FPR}) d(\text{FPR}) \tag{5}$$

où VP = Vrais Positifs, VN = Vrais Négatifs, FP = Faux Positifs, FN = Faux Négatifs.

Tableau Comparatif des Résultats

TABLE 5 – Comparaison des performances sur l'ensemble de test (93 355 vols)

Modèle	Accuracy	F1-Score	Précision	Rappel	ROC-AUC	Avg. Prec.
Rég. Logistique	0.5671	0.3381	0.2385	0.5801	0.5964	0.2387
Random Forest	0.6241	0.3673	0.2704	0.5726	0.6476	0.2986
XGBoost	0.6176	0.3820	0.2760	0.6202	0.6644	0.3153
LightGBM	0.6128	0.3801	0.2735	0.6230	0.6638	0.3150

La ligne en vert correspond au meilleur modèle selon le ROC-AUC

Analyse des Résultats par Modèle

Régression Logistique

Le modèle baseline produit les performances les plus faibles mais reste au-dessus d'un classificateur aléatoire (ROC-AUC = 0.50). Son accuracy de 56,7% avec un rappel de 58% montre qu'il détecte une fraction raisonnable des retards, mais génère de nombreux faux positifs (précision 23,9%).

Random Forest

Nette amélioration par rapport au baseline : ROC-AUC passe à 0.648 (+8,6%). L'accuracy de 62,4% est la plus élevée de tous les modèles, mais cela s'explique en partie par un rappel légèrement plus bas (57,3%). Le Random Forest offre une bonne stabilité grâce à l'agrégation de 100 arbres.

XGBoost — Meilleur Modèle

XGBoost : Modèle Recommandé

XGBoost obtient le **meilleur ROC-AUC** (0.664) et la meilleure **Average Precision** (0.315), ce qui en fait le modèle le plus performant pour discriminer les vols retardés des vols à l'heure. Son rappel de 62% signifie qu'il détecte 6 retards sur 10 correctement.

LightGBM

Performances quasi-identiques à XGBoost (ROC-AUC 0.664 vs 0.663), avec l'avantage d'un temps d'entraînement significativement réduit sur de grands datasets. En production, LightGBM serait préféré pour sa scalabilité.

Interprétation des Matrices de Confusion

Pour XGBoost sur 93 355 vols de test :

- **Vrais Positifs** : $\approx 11\,500$ retards correctement prédits
- **Faux Négatifs** : $\approx 7\,000$ retards manqués (vols annoncés à l'heure, finalement retardés)
- **Faux Positifs** : $\approx 30\,000$ fausses alarmes
- **Vrais Négatifs** : $\approx 44\,000$ vols à l'heure correctement identifiés

Le ratio FP élevé est inévitable avec un déséquilibre 80/20 et des features incomplètes (absence des données météo temps-réel, état des pistes, etc.).

Importance des Variables

L'analyse d'importance des features (Random Forest, XGBoost, LightGBM) révèle un consensus sur les variables les plus prédictives :

1. **Distance du vol** : les longs-courriers accumulent plus facilement des retards
2. **Temps de vol programmé** : corrélé à la distance, proxy de la complexité
3. **Heure de départ** : effet cascade quotidien
4. **Aéroport de départ** : certains hubs sont structurellement plus congestionnés
5. **Compagnie aérienne** : reflète les pratiques opérationnelles différentes
6. **Mois** : saisonnalité et trafic
7. **Jour de la semaine** : pattern hebdomadaire de demande

Limites et Améliorations Proposées

Limites Actuelles

Limites identifiées

- **Absence de données météo temps-réel** : vent, visibilité, précipitations sont les principaux facteurs non capturés
- **Absence d'historique de l'avion** : le retard précédent de l'appareil (rotation) est très prédictif mais non disponible
- **Déséquilibre de classes** : malgré les stratégies de pondération, le modèle reste biaisé
- **Features statiques** : les features capturent des tendances globales, pas les conditions dynamiques du jour J
- **Échantillonnage** : 500 000 vols utilisés sur 3 millions disponibles

Pistes d'Amélioration

Amélioration des Données

- **Intégration météo** : API OpenWeatherMap ou Météo-France pour données historiques par aéroport et date
- **Données de rotation** : retard du vol précédent effectué par le même avion
- **Données NAS (National Airspace System)** : saturation du contrôle aérien
- **Données aéroport** : taux d'occupation des pistes, incidents récents
- **Features cycliques** : encoder l'heure et le mois comme $\sin(2\pi x/T)$, $\cos(2\pi x/T)$ pour préserver la continuité

Amélioration des Modèles

- **Optimisation des hyperparamètres** : recherche bayésienne (Optuna) plutôt que manuelle
- **SMOTE / ADASYN** : suréchantillonnage synthétique de la classe minoritaire
- **Modèles neuronaux** : TabNet, réseaux de neurones tabulaires
- **Threshold tuning** : optimiser le seuil de décision (par défaut 0.5) pour maximiser le rappel ou le F1
- **Stacking / Blending** : combiner les prédictions des 4 modèles
- **Entraînement sur dataset complet** : utiliser les 3 millions de vols

Amélioration du Déploiement

- **Mise à jour incrémentale** : réentraînement périodique avec les nouveaux vols
- **API REST** : exposer le modèle via FastAPI pour intégration systèmes
- **Monitoring** : suivi de la dérive des données (data drift) en production
- **A/B Testing** : comparer les décisions prises avec/sans le système
- **Explicabilité SHAP** : expliquer chaque prédiction individuellement

Déploiement de l'Application Streamlit

Architecture de l'Application

L'application Streamlit offre une interface utilisateur intuitive permettant :

- La prédiction interactive pour un vol individuel
- La visualisation des performances des 4 modèles
- L'exploration des analyses EDA
- La comparaison des prédictions entre modèles

Structure du Projet

Listing 2 – Structure des fichiers du projet

```
1 flight_delay_project/  
2 |-- src/  
3 |   |-- app.py                # Application principale Streamlit  
4 |-- outputs/  
5 |   |-- eda_analysis.png      # Figures EDA  
6 |   |-- model_comparison.png  
7 |   |-- confusion_matrices.png  
8 |   |-- feature_importance.png  
9 |   |-- roc_curves.png  
10 |   |-- results_table.json  
11 |   |-- stats.json  
12 |-- models/  
13 |   |-- regression_logistique.pkl  
14 |   |-- random_forest.pkl  
15 |   |-- xgboost.pkl  
16 |   |-- lightgbm.pkl  
17 |   |-- le_dep.pkl  
18 |   |-- le_arr.pkl  
19 |   |-- le_comp.pkl  
20 |-- reports/  
21 |   |-- rapport_retards_vols.tex
```

Instructions de Déploiement

Listing 3 – Commandes de déploiement

```
1 # Installation des dépendances  
2 pip install streamlit scikit-learn xgboost lightgbm  
3 pip install pandas numpy matplotlib seaborn joblib  
4  
5 # Lancement de l'application  
6 cd flight_delay_project/  
7 streamlit run src/app.py --server.port 8501  
8  
9 # Acces dans le navigateur
```

10

http://localhost:8501

Fonctionnalités de l'Application

TABLE 6 – Pages et fonctionnalités de l'application Streamlit

Page		Fonctionnalités
Accueil		Métriques clés, description du projet, résumé du meilleur modèle
Prédiction		Formulaire interactif, résultat avec probabilités, comparaison entre modèles
Performance	Mo-	Tableau comparatif avec surbrillance du meilleur, courbes ROC, matrices de confusion, importance des features
dèles		
Analyse EDA		Visualisations de la distribution des retards, tendances temporelles, géographie

Conclusion

Synthèse

Ce projet a démontré la faisabilité d'un système de prédiction de retards de vols basé sur le Machine Learning, appliqué à un dataset industriel de grande taille (3 millions de vols).

Les principaux résultats sont :

Résultats Clés

- **XGBoost** est le meilleur modèle avec un ROC-AUC de **0.664**
- **LightGBM** offre des performances quasi-équivalentes avec un avantage en vitesse
- Les features temporelles (heure, mois) et la distance sont les plus prédictives
- Un taux de rappel de 62% permet de détecter la majorité des retards significatifs
- L'application Streamlit déployée rend le modèle accessible à des non-experts

Perspectives

L'intégration de données météorologiques temps-réel et de l'historique de rotation des avions constitue la piste d'amélioration la plus prometteuse. Des études ont montré que ces deux types de données peuvent porter le ROC-AUC au-delà de 0.80 sur des problèmes similaires.

Pour un déploiement industriel, les prochaines étapes seraient :

1. Développer une API REST pour l'intégration dans les systèmes de gestion aéroportuaire
2. Mettre en place un pipeline de réentraînement automatique (MLOps)
3. Implémenter un système d'explication des prédictions (SHAP values)
4. Réaliser un test en conditions réelles sur un aéroport pilote
5. Évaluer l'impact économique des prédictions correctes vs erreurs de prédiction

Valeur Métier

Un système de prédiction performant permet d'économiser en moyenne entre **500 et 2 000 euros par vol retardé** identifié à l'avance, grâce à :

- La notification proactive des passagers (réduction des compensations)
- L'optimisation du routing des équipages et des avions
- La réduction des effets cascade sur les vols suivants
- L'amélioration de la satisfaction client et de l'image de marque

Appliqué aux 93 262 vols retardés de notre dataset (19% du total), un système avec 62% de rappel permettrait de traiter proactivement environ **57 822 retards**, représentant un potentiel d'économies de plusieurs dizaines de millions d'euros sur l'ensemble du réseau.

Rapport généré dans le cadre d'un projet d'analyse de données — 2024
Technologies : Python 3.12 · scikit-learn · XGBoost · LightGBM · Streamlit